

FET445 VERİ MADENCİLİĞİ

E-TİCARET SİPARİŞLERİNDE GEÇ TESLİMATLARIN TAHMİN EDİLMESİ

GRUP:LATİNO

TALHA DEMİREL 22040301060

06.01.2026

PROBLEM TANIMI

E-ticaret platformlarında siparişlerin zamanında teslim edilememesi, müşteri memnuniyetsizliğine ve operasyonel kayıplara yol açmaktadır. Bu projede, bir siparişin geç teslim edilip edilmeyeceği, sipariş anında mevcut bilgiler kullanılarak tahmin edilmektedir.

Amaç:

Sipariş oluştuğu anda, gecikme riski taşıyan siparişleri önceden tespit edebilmek.

VERİ SETİ TANITIMI

- **Dataset:**
Brazilian E-Commerce Public Dataset (Olist)
- **Kaynak:**
<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce/data>
- **Boyut:**
 - 99992 X 13
 - Çoklu CSV yapısı (orders, customers, products, payments vb.)
- **Hedef Değişken:**
delivered_late
 - 1 → Geç teslim
 - 0 → Zamanında teslim

VERİ SETİNİN ÖNEMLİ ÖZELLİKLERİ (EDA)

- Veri seti yüksek derecede dengesizdir (~%95 zamanında, ~%5 geç teslim)
- Sayısal değişkenlerde aykırı değerler mevcuttur
- Lojistik ve fiyatla ilgili değişkenler gecikme üzerinde etkilidir
- **Kullanılan EDA Görselleri:**
- Histogramlar (dağılımlar)
- Boxplotlar (outlier analizi)
- Korelasyon matrisi

VERİ HAZIRLAMA & FEATURE ENGINEERING

•Uygulanan Adımlar:

- Eksik verilerin doldurulması
- Gereksiz kolonların silinmesi
- Kategorik değişkenlerin encode edilmesi
- Aykırı değer analizi
- Data leakage içeren değişkenlerin kaldırılması
- Train 0.8 Test 0.2 olarak ayrılmıştır

FEATURE IMPORTANCE VE KULLANILAN METRİKLER

One-Hot Encoding sonrası oluşan yüksek boyutlu feature setinde, özelliklerin modele katkısını analiz etmek amacıyla Random Forest tabanlı feature importance yöntemi kullanılmıştır.

Kullanılan Metrikler:

- Imbalanced Dataset olduğu için:
- ROC-AUC
- F1 Score
- Confusion Matrix
- Accuracy

Feature Set: 'order_id', 'customer_id', 'order_status', 'order_purchase_timestamp', 'order_approved_at', 'order_delivered_carrier_date', 'order_delivered_customer_date', 'order_estimated_delivery_date', 'price', 'freight_value', 'customer_city', 'customer_state', 'review_score', 'delivered_late', 'delivery_time_days', 'carrier_delay_days', 'delivery_diff_estimated_days', 'price_freight_ratio'

KULLANILAN MODELLER

- Bu projede, e-ticaret siparişlerinde geç teslimat tahmini problemini çözmek amacıyla farklı model aileleri tercih edilmiştir.

Logistic Regression, yorumlanabilir ve güçlü bir baseline model oluşturmak için kullanılmıştır.

Random Forest, doğrusal olmayan ilişkileri yakalayabilmesi ve feature importance analizi sunması nedeniyle tercih edilmiştir.

LightGBM ve XGBoost, yüksek performans, ölçeklenebilirlik ve imbalanced veri setlerinde etkin öğrenme yetenekleri sebebiyle modele dahil edilmiştir.

- Bu yaklaşım sayesinde, basit modellerden gelişmiş modellere uzanan karşılaştırmalı ve kapsamlı bir analiz gerçekleştirilmiştir.

MODEL KARŞILAŞTIRMA TABLOSU

Model	ROC-AUC	F1	Accuracy	Confusion Matrix
Random Forest	~0.76	~0.34	~0.81	[15214 2988 611 953]
LightGBM	~0.76	~0.34	~0.81	[15089 3113 595 969]
Logistic Regression	~0.71	~0.33	~0.79	[14744 3458 564 1000]
XGBoost	0.76	0.33	0.80	[14856 3346 576 988]

BEST MODEL: LIGHTGBM

- **Model geliştirilirken kullanılan yaklaşımlar:**
 - Veri ön işleme adımlarının pipeline yapısı içinde uygulanması
 - Teslimat sonrası oluşan değişkenler çıkarılarak data leakage önlenmesi
 - Sınıf dengesizliği dikkate alınarak model performansının ROC-AUC ve F1 skorları üzerinden değerlendirilmesi
- **Hyper-parametre ayarlama:**
 - GridSearchCV kullanılmıştır
 - Optimizasyon metriği olarak ROC-AUC tercih edilmiştir
 - LightGBM, Random Forest ve XGBoost ile benzer ROC-AUC değerlerine ulaşmasına rağmen, daha hızlı eğitim süresi ve yüksek ölçeklenebilirliği sayesinde performans-verimlilik dengesini en iyi sağlayan model olmuştur. Bu nedenle proje kapsamında en uygun (best) model olarak seçilmiştir.

SONUÇLAR VE ÇIKARIMLAR

- Bu çalışmada, e-ticaret siparişlerinde geç teslimat tahmini problemi için Logistic Regression, Random Forest, LightGBM ve XGBoost modelleri karşılaştırılmıştır. Sonuçlar, ağaç tabanlı ve boosting modellerinin (Random Forest, LightGBM, XGBoost) doğrusal modele kıyasla daha yüksek ayırt edicilik sunduğunu (ROC- AUC ≈ 0.76) göstermektedir.
- Tüm modellerde accuracy değerleri yüksek olmasına rağmen, F1 skorlarının düşük kalması, veri setindeki sınıf dengesizliğinin doğrudan bir sonucudur. Modeller zamanında teslim edilen siparişleri başarıyla tahmin ederken, geç teslim edilen siparişleri yakalama konusunda sınırlı performans sergilemiştir.
- Confusion matrix analizleri, azınlık sınıfın tespit edilmesinin zor olduğunu ve accuracy metriğinin tek başına yeterli olmadığını ortaya koymaktadır. Performans, hız ve ölçeklenebilirlik birlikte değerlendirildiğinde LightGBM, pratik kullanım açısından en dengeli model olarak öne çıkmıştır.